

练习题 1（4 学时）

1) 线性回归建模与预测分析

- 使用 Boston Housing 或 California Housing 数据集，构建线性回归模型。
- 比较使用均方误差（MSE）和决定系数（ R^2 ）评估模型性能的差异。
- 绘制真实值与预测值的散点图，并分析拟合效果。

2) 支持向量机与核方法对比实验

- 使用 Moon 或 Circle 人工数据集，对比线性核与 RBF 核的分类结果。
- 可视化决策边界，分析非线性核函数在复杂分布数据上的优势。
- 对不同惩罚参数 C 的取值进行实验，观察模型泛化能力变化。

3) K 近邻算法参数分析

- 使用手写数字（如 MNIST 小样本）或鸢尾花数据集。
- 分别设置 $k=1, 3, 5, 15$ ，比较不同 k 值对分类准确率的影响。
- 探讨样本标准化（如 MinMaxScaler）对 KNN 性能的影响。

4) 决策树构建与剪枝实验

- 使用鸢尾花或成人收入数据集构建决策树分类器。
- 分别采用信息增益和基尼指数作为划分标准，比较其模型结构和准确率差异。
- 使用预剪枝（设置最大深度、最小样本数）与后剪枝（基于测试集误差）策略，分析模型复杂度与性能的平衡。

练习题 2（4 学时）

1) Bagging 方法实践与性能分析

任务描述：使用 `sklearn` 中的 `BaggingClassifier` 在 UCI Wine 数据集上训练一个基于决策树的 Bagging 模型，并与单棵决策树的性能进行对比。

- 载入 Wine 数据集并进行训练集/测试集划分。
- 使用 `DecisionTreeClassifier` 作为基学习器，构建 Bagging 模型。
- 评估并比较 Bagging 模型与单棵决策树在测试集上的准确率与方差。
- 使用 `learning_curve` 或交叉验证探究模型在不同训练样本量下的稳定性。
- 可视化模型在不同子采样比例（`max_samples`）下的性能变化。

2) Boosting 方法实现与可视化分析

任务描述：利用 `GradientBoostingClassifier` 在 Wine 数据集上训练模型，分析模型在不同学习率、弱学习器深度、迭代轮数下的表现。

- 训练一个基本的 GBDT 模型，记录其准确率与损失变化。
- 尝试不同的 `learning_rate`（如 0.01, 0.1, 0.3）与 `max_depth`（如 1, 3, 5）组合，观察模型是否过拟合或欠拟合。
- 绘制训练误差与测试误差随迭代轮数（`n_estimators`）变化的曲线。
- 提取特征重要性并绘图。

3) Stacking 方法构建与解释

任务描述：使用 `StackingClassifier` 构建一个堆叠集成模型，将 SVM、随机森林、GBDT 作为基模型，逻辑回归作为元模型。

- 分别训练各个基模型并获取其预测概率。
- 使用 5 折交叉验证构建元特征，训练元学习器。
- 与单一基模型和简单投票法进行性能比较。
- 可视化基模型输出之间的相关性热力图。
- 分析元模型的系数或特征重要性，解释其对最终预测的影响。

练习题 3（4 学时）

1) 特征选择方法对比实验

- 随机选取一个 UCI 公开数据集（如乳腺癌诊断数据集）；
- 分别使用过滤法（如方差选择法）、包裹法（如递归特征消除 RFE）和嵌入法（如基于 Lasso 回归）进行特征选择；
- 比较不同方法所选特征的数量及分类准确率差异（可使用 SVM 或逻辑回归）；
- 分析各方法对模型性能与训练时间的影响。

2) 主成分分析（PCA）与 t-SNE 可视化比较

- 使用 MNIST 手写数字图像数据集中的部分样本；
- 分别采用 PCA 与 t-SNE 将 784 维图像特征降至二维；
- 使用二维散点图可视化不同类别数字的分布情况；
- 比较两种方法在类别可分性与局部结构保留方面的表现差异。

3) 自编码器重构效果分析

- 使用 Keras 或 PyTorch 搭建一个简单自编码器结构；
- 输入 MNIST 图像进行训练与重构，输出重构图像；
- 观察原始图像与重构图像的结构、边缘清晰度等；
- 结合重构误差（如 MSE）分析自编码器的表示能力和压缩效率。

练习题 4（4 学时）

1) 神经网络训练流程实践与可视化

- 使用 Keras 或 PyTorch 构建一个三层全连接神经网络，用于 MNIST 手写数字分类任务；
- 实现标准化数据预处理流程，并完成模型初始化、前向传播、损失计算、反向传播与优化过程；
- 训练过程中使用 TensorBoard（或 Matplotlib）可视化损失与准确率曲线；
- 尝试不同初始化方式（如 Xavier、He）与优化器（如 SGD、Adam），分析训练收敛曲线差异。

2) 构建并训练一个简化版卷积神经网络

- 使用 CIFAR-10 数据集，设计一个包含两个卷积层、两个池化层和一个全连接层的简单 CNN 模型；
- 训练模型至少 10 个 epoch，记录训练集和验证集的损失及准确率；
- 绘制训练过程中的损失曲线和准确率曲线，分析模型的训练情况；
- 尝试调整卷积核数量和大小，比较对模型性能的影响。

3) 实现数据增强并分析其效果

- 在训练数据上实现至少三种数据增强方法（如随机翻转、旋转、裁剪等）；
- 训练同一 CNN 模型两次，一次使用原始数据，一次使用增强数据；
- 比较两种训练方式下的测试准确率及训练过程中的损失变化；
- 总结数据增强对模型泛化能力的影响。